

# DENSITY ESTIMATION USING REAL NVP

презентацию подготовил студент ВШЭ, Трошин Сергей.  
2019

# Что будет рассказано?

1. Задача генеративной модели
2. Формула замены переменной
3. Affine Coupling layer
4. Правило композиции
5. Ранняя факторизация
6. Batch Normalisation
7. Результаты

# Общая постановка задачи для генеративных моделей

Задача генеративных моделей - генерировать новые данные по имеющимся обучающим примерам.

$X, y$  - выборка


$X, y \sim p(X, y)$

$\hat{p}(X, y) - ?$

Хотим новые объекты из распределения  $\hat{p}(X | y)$

# Общая постановка задачи для генеративных моделей

Зачастую, генеративные модели учатся, принимая на вход шум (точки из латентного пространства) и, возможно, другую мета-информацию, порождать объект, например, картинку.



# Примеры задач




**Генерация музыки и речи**



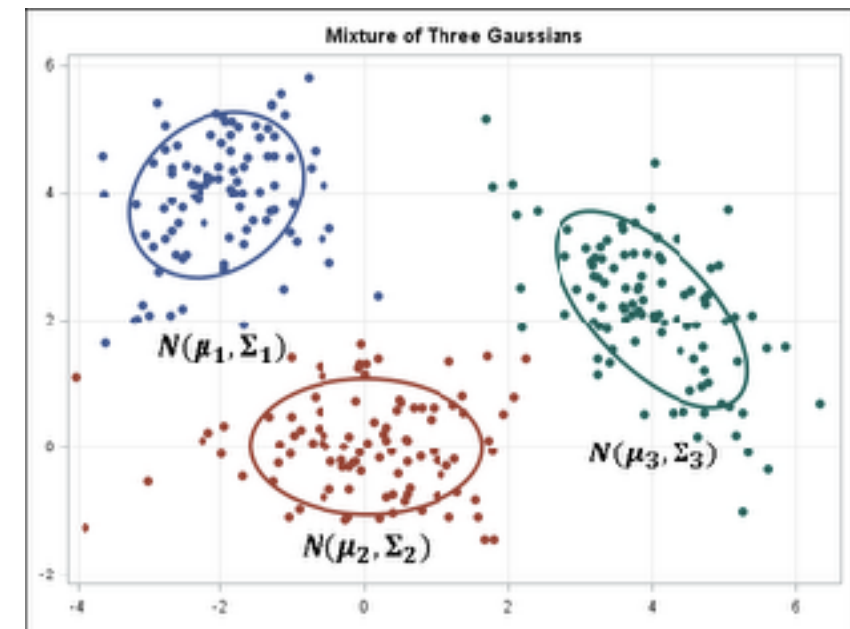
**Рендеринг в реальном времени**

**Работая с реальными системами, мы хотим быструю генерацию, точную вычислимость, разнообразие.**


# Подходы




**GANs (Goodfellow et al. 2014)**



**GMM + EM**



**Autoregressive GM (Aaron et al. 2016)**



**Variational autoencoder (Kingma et al. 2013)**

Real-valued non-volume preserving (real NVP)  
transformations




# Идея Real NVP

## Inference


$$x \sim \hat{p}_X$$

$$z = f(x)$$

Data space  $\mathcal{X}$





Latent space  $\mathcal{Z}$



## Generation


$$z \sim p_Z$$

$$x = f^{-1}(z)$$





Вспомним, как меняется площадь при смене базиса.



$$e_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad e_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$e'_1 = \begin{bmatrix} 2 \\ c \end{bmatrix} \quad e'_2 = \begin{bmatrix} 0 \\ b \end{bmatrix}$$

$$S_1 = 1 \cdot 1 = 1$$

$$S_2 = b \cdot \langle e'_1, e_1 \rangle = 2b$$


**не зависит от  $c$**

$$C_{e \rightarrow e'} = \begin{bmatrix} 2 & 0 \\ c & b \end{bmatrix}$$

**диагональная**

$$S_2 = |C_{e \rightarrow e'}| = 2b$$

# Замена переменной



$$C_{e \rightarrow e'} = \begin{bmatrix} 2 & 0 \\ c & b \end{bmatrix}$$

$$p_y(y) = p_z(z) S_2^{-1}$$

$$z \sim U([0,1]^2) \quad y = g(z) = C_{e' \rightarrow e} z$$


$$p_z(z) = \frac{1}{S_1} \quad p_y(y) = ?$$

$$p_y(y) = p_z(z) \left| \det \left( \frac{\partial g(z)}{\partial z^T} \right) \right|^{-1}$$

считаем Якобиан за  $O(n)$ !  
вместо  $O(n^3)$

‘с’ может быть сложной функцией!

# Замена переменной



Пример хорошего отображения  
(диффеоморфизм)

При соблюдении условий

1. Отображение  $g$  - взаимно-однозначно.
2.  $g$  дифференцируемо.
3. Якобиан отображения  $J_g(x) \neq 0$ :

Справедлива теорема

$$p_y(y) = p_z(z) \left| \det \left( \frac{\partial g(z)}{\partial z^T} \right) \right|^{-1}$$

то, что будем максимизировать  
(максимизация правдоподобия)

# Affine coupling layer

$$y_{1:d} = x_{1:d}$$

$$y_{d+1:D} = x_{d+1:D} \odot \exp \left( \underline{s(x_{1:d})} \right) + \underline{t(x_{1:d})},$$

Как будет выглядеть матрица Якоби такой функции?

$$\frac{\partial y}{\partial x^T} = \begin{bmatrix} \mathbb{I}_d & 0 \\ \frac{\partial y_{d+1:D}}{\partial x_{1:d}^T} & \text{diag} \left( \exp \left[ \underline{s(x_{1:d})} \right] \right) \end{bmatrix}$$

$s, t$  - одни и те же  
пусть это будет  
нейросети!

---

Как посчитать обратную функцию?

$$\begin{cases} x_{1:d} &= y_{1:d} \\ x_{d+1:D} &= \left( y_{d+1:D} - \underline{t(y_{1:d})} \right) \odot \exp \left( - \underline{s(y_{1:d})} \right) \end{cases}$$

---

# Правило композиции

$$\frac{\partial(f_b \circ f_a)}{\partial x_a^T}(x_a) = \frac{\partial f_a}{\partial x_a^T}(x_a) \cdot \frac{\partial f_b}{\partial x_b^T}(x_b = f_a(x_a))$$

$$\det(A \cdot B) = \det(A) \det(B).$$

$$(f_b \circ f_a)^{-1} = f_a^{-1} \circ f_b^{-1}.$$


**Позволяет нам комбинировать простые преобразования  
в сложные композиции.**

# Применение к изображениям

Маскирование для affine coupling layer




шахматное маскирование



маскирование по каналам


Клетками одного цвета обозначены  $x[1:d]$ , а другого  $x[d+1:D]$



**фиксируем одни переменные, обновляем другие**



# Ранняя гауссинизация



**быстрее  
эффективно по памяти**

**половина переменных на каждом этапе фиксируется  
(считаем, что это уже гаусовские латентные переменные)**

# Ключевые преимущества

- **Скорость. В отличие от Pixel RNN.**
- **Вычислимое правдоподобие. В отличие от GAN.**

# Модель для больших датасетов

- s, t - сверточные резидьюальные сети
- batch normalisation
- weight normalisation

# Batch Normalisation

- считаем моменты  $\sigma^2$ ,  $\mu$

$$x \rightarrow \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

$$J = (\sqrt{\sigma^2 + \epsilon})^{-1}$$

Аппроксимация

# Результаты

Dataset	PixelRNN [46]	Real NVP	Conv DRAW [22]	IAF-VAE [34]
<b>CIFAR-10</b>	3.00	3.49	< 3.59	< 3.28
<b>Imagenet</b> (32 × 32)	3.86 (3.83)	4.28 (4.26)	< 4.40 (4.35)	
<b>Imagenet</b> (64 × 64)	3.63 (3.57)	3.98 (3.75)	< 4.10 (4.04)	
<b>LSUN</b> (bedroom)		2.72 (2.70)		
<b>LSUN</b> (tower)		2.81 (2.78)		
<b>LSUN</b> (church outdoor)		3.08 (2.94)		
<b>CelebA</b>		3.02 (2.97)		

Bits/dim (чем меньше, тем лучше)

# Примеры генерации изображений.





# Интер/Экстра-поляция



На рисунке представлены изображения, полученные путем интерполяции на сфере в пространстве латентных переменных.



# Summary

- Вычислимое оценивание плотности с помощью DNN и формулы замены переменной
- Быстрый вывод и сэмплирование
- качество на уровне других моделей и связанные изображения

# Материалы

- Оригинальная статья. <https://arxiv.org/pdf/1605.08803.pdf>
- Презентация автора. [https://www.periscope.tv/hugo\\_larochelle/1ypKdAVmbEpGW](https://www.periscope.tv/hugo_larochelle/1ypKdAVmbEpGW)