

# Non-negative matrix factorization

Неотрицательные матричные разложения

---

Сергей Горбачев

12 октября 2018 г.

группа 162

1. Постановка задачи
2. Дивергенции
3. Проблемы NMF
4. Мультипликативные обновления
5. Алгоритмы для функций потерь
6. Инициализация алгоритмов
7. Применение к стохастическим матрицам

# Постановка задачи

У нас есть неотрицательная прямоугольная матрица  $X$  размера  $m \times n$

Мы хотим приблизить ее произведением двух прямоугольных неотрицательных матриц  $W$  и  $H$

$$X \approx WH \equiv Q \quad X, Q \in R_+^{m \times n} \quad (1)$$

$$W \in R_+^{m \times r}, \quad H \in R_+^{r \times n}$$

$$r < \min(m, n)$$

# Постановка задачи

Введя меру потерь (дивергенцию)  $D(X, WH)$ , получаем оптимизационную задачу:

$$(W^*, H^*) = \arg \min_{W \geq 0, H \geq 0} D(X, WH) \quad (2)$$

# Примеры дивергенции

$$D(X, Q) = \sum_{i=1}^m \sum_{j=1}^n d(p_{ij}, q_{ij}) \quad (3)$$

$$d(p, q) > 0$$

$$d(p, q) = 0 \Leftrightarrow p = q$$

Название	$d(p, q)$
норма $l_1$	$ p - q $
норма Фробениуса	$(p - q)^2$
обобщённая дивергенция Кульбака-Лейблера	$p \ln \frac{p}{q} - p + q$
дивергенция Итакура-Саито	$\ln \frac{q}{p} + \frac{p}{q} - 1$
расстояние Хеллингера	$(\sqrt{p} - \sqrt{q})^2$
$\chi^2$ Пирсона	$\frac{(\sqrt{p} - \sqrt{q})^2}{q}$
$\chi^2$ Неймана	$\frac{(\sqrt{p} - \sqrt{q})^2}{p}$

# Связь дивергенции с правдоподобием

Во многих случаях дивергенция соответствует правдоподобию, то есть существует плотность  $p(X|Q)$ , такая, что при каких-то  $a$  и  $b$

$$-\ln p(X|Q) = aD(X, Q) + b \quad (4)$$

Например норма Фробениуса соответствует гауссовскому распределению

$$p(X|Q) = \prod_{ij} N(p_{ij} | q_{ij}, \sigma^2) = \prod_{ij} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(p_{ij}-q_{ij})^2}{2\sigma^2}} \quad (5)$$

Кульбака-Лейблера - пуассоновскому, Итакура-Саито - гамма распределению

- NP-трудна
- Некорректно поставлена: если  $W_0, H_0$  — решение задачи, то пара  $W = W_0 D, H = D^{-1} H_0$  тоже может быть решением
- $D(X, WH)$  не выпукла по совокупности аргументов  $(W, H)$ , поэтому обычно используют блочно-покоординатные методы минимизации, то есть поочередно обновляем  $W$  и  $H$

$$H^t = f(X, W^{t-1}, H^{t-1}) \quad (6)$$

$$W^t = f(X^T, (H^t)^T, (W^{t-1})^T)^T$$

- Можем гарантировать только схождение к локальному минимуму

Локальный минимум по условиям Каруша-Куна-Таккера:

$$\begin{aligned} W^* \geq 0, \quad \nabla_W D(X, W^* H^*) &\geq 0, \quad W^* \otimes \nabla_W D(X, W^* H^*) = 0 \\ H^* \geq 0, \quad \nabla_H D(X, W^* H^*) &\geq 0, \quad H^* \otimes \nabla_H D(X, W^* H^*) = 0 \end{aligned} \quad (7)$$



Поочередный градиентный спуск:

$$\begin{aligned}h_{kj} &\leftarrow h_{kj} - \nu_{kj} \frac{\partial D(X, WH)}{\partial h_{kj}} \\w_{ik} &\leftarrow w_{ik} - \eta_{ik} \frac{\partial D(X, WH)}{\partial w_{ik}} \\k &= 1, \dots, r, i = 1, \dots, m, j = 1, \dots, n\end{aligned}\tag{8}$$

В таком виде не подходит, так как не учитывает ограничение неотрицательности

# Мультипликативные обновления

Выбираем шаг так, чтоб обновления были мультипликативными

$$\begin{aligned}\frac{\partial D(X, WH)}{\partial h_{kj}} &= [\nabla_H]_{kj} = [\nabla_H^+]_{kj} - [\nabla_H^-]_{kj} \\ \nu_{ki} &= \frac{h_{kj}}{[\nabla_H^+]_{kj}} \\ h_{kj} &\leftarrow h_{kj} - \frac{h_{kj}}{[\nabla_H^+]_{kj}} ([\nabla_H^+]_{kj} - [\nabla_H^-]_{kj}) = h_{kj} \frac{[\nabla_H^-]_{kj}}{[\nabla_H^+]_{kj}}\end{aligned}\tag{9}$$

В матричном виде:

$$H \leftarrow H \otimes \nabla_H^- \oslash \nabla_H^+\tag{10}$$

$\otimes$  - поэлементное умножение матриц,  $\oslash$  - поэлементное деление

# Мультипликативные обновления

## Плюсы

- просты в реализации
- масштабируются и приспособабляются к работе с разреженными матрицами

## Минусы

- Скорость сходимости невелика (можно увеличить обновляя одну матрицу несколько раз подряд)
- Если  $h_{kj} = 0$ , то он останется нулем, даже если  $[\nabla_n]_{kj} < 0$ , поэтому может не сойтись к локальному минимуму

Оптимизационная задача:

$$(W^*, H^*) = \arg \min_{W \geq 0, H \geq 0} \|X - WH\|_F^2 \quad (11)$$

Без ограничения неотрицательности решение можно было бы получить с помощью SVD.

Для нормы Фробениуса мультипликативные обновления выглядят так:

$$\begin{aligned}\nabla_H &= W^T W H - W^T X \\ H &\leftarrow H \otimes (W^T X) \oslash (W^T W H)\end{aligned}\tag{12}$$

Известно, что при таком обновлении функция потерь монотонно невозрастает\*

## Модификации

- Отделять элементы  $W$  и  $H$  от нуля небольшой константой  $\varepsilon$

$$H \leftarrow \max(\varepsilon, H \otimes \nabla_H^- \oslash \nabla_H^+) \quad (13)$$

Показанно, что этот алгоритм сходится к локальному решению такой задачи:

$$(W_\varepsilon^*, H_\varepsilon^*) = \arg \min_{W \geq \varepsilon, H \geq \varepsilon} \|X - WH\|_F^2 \quad (14)$$

- После каждого шага реинициализировать  $\varepsilon$  только те элементы, для которых компонента градиента отрицательна

# Метод попеременных наименьших квадратов

Alternating Least Squares (ALS): на каждом шаге находится решение задачи наименьших квадратов по одной из компонент, а затем берется проекция на неотрицательную область

$$\begin{aligned} H &\leftarrow \max(\arg \min_{Z \in R^{r \times n}} \|X - WZ\|_F^2, 0) = \\ &= \max((W^T W)^{-1} W^T X, 0) \end{aligned} \tag{15}$$

Метод быстрый, но итерационный процесс не сходится, функция потерь не монотонна. Можно использовать для инициализации других методов.

# Метод попеременных неотрицательных наименьших квадратов

Alternating Nonnegative Least Squares (ANLS): на каждом шаге находится покомпонентный минимум в неотрицательной области

$$H \leftarrow \max(\arg \min_{H \geq 0} \|X - WH\|_F^2, 0) \quad (16)$$

Есть разные методы нахождения покомпонентных минимумов, но все они очень долгие. Можно использовать для уточнения решения, найденного более простыми методами.



# Метод иерархических попеременных наименьших квадратов

Hierarchical alternating least squares (HALS): на каждом шаге находится минимум в неотрицательной области по столбцу  $w_k$  или строке  $h_k$

$$\begin{aligned} h_k &\leftarrow \arg \min_{h_k \geq 0} \|X - WH\|_F^2 = \\ &= \max(0, \frac{w_k^T X - \sum_{l \neq k} w_k^T w_l h_l}{w_k^T w_k}) \end{aligned} \quad (17)$$

Каждая итерация требует малых вычислений и сходится быстрее метода мультипликативных обновлений, однако чувствителен к начальным значениям

# Метод иерархических попеременных наименьших квадратов

Hierarchical alternating least squares (HALS): на каждом шаге находится минимум в неотрицательной области по столбцу  $w_k$  или строке  $h_k$

$$\begin{aligned} h_k &\leftarrow \arg \min_{h_k \geq 0} \|X - WH\|_F^2 = \\ &= \max(0, \frac{w_k^T X - \sum_{l \neq k} w_k^T w_l h_l}{w_k^T w_k}) \end{aligned} \quad (18)$$

Каждая итерация требует малых вычислений и сходится быстрее метода мультипликативных обновлений, однако чувствителен к начальным значениям

Оптимизационная задача:

$$\begin{aligned}(W^*, H^*) &= \arg \min_{W \geq 0, H \geq 0} D_{KL}(X, WH) \\ &= \arg \min_{W \geq 0, H \geq 0} \sum_{i=1}^m \sum_{j=1}^n \left( p_{ij} \ln \frac{p_{ij}}{[WH]_{ij}} - p + [WH]_{ij} \right)\end{aligned}\tag{19}$$

# NMF с обобщённой дивергенцией Кульбака-Лейблера

Метод мультипликативных обновлений

$$\begin{aligned} [\nabla_H]_{k,j} &= \sum_{i=1}^m w_{ik} - \sum_{i=1}^m w_{ik} \frac{x_{ij}}{[WH]_{ij}} \\ h_{kj} &\leftarrow h_{kj} \frac{\sum_{i=1}^m w_{ik} \frac{x_{ij}}{[WH]_{ij}}}{\sum_{i=1}^m w_{ik}} \\ \nabla_H &= W^T J_{m \times n} - W^T (X \odot (WH)) \\ H &\leftarrow H \otimes (W^T (X \odot (WH))) \odot (W^T J_{m \times n}) \end{aligned} \tag{20}$$

Функция потерь так же монотонно невозрастает

# Инициализация алгоритмов

Методы сходятся локально, поэтому начальные значения играют большую роль

- Случайная
- Кластеризация столбцов  $X$ , центроиды инициализируют столбцы  $W$ , а  $H$  - матрица принадлежности к кластерам
- SVD для  $X$  находится  $r$  наибольших сингулярных троек  $(u_k, s_k, v_k)$

$$W_{:,k}^0 = u_k^{+/-} \sqrt{s_k \frac{\|v_k^{+/-}\|}{\|u_k^{+/-}\|}}, \quad H_{k,:}^0 = v_k^{+/-} \sqrt{s_k \frac{\|u_k^{+/-}\|}{\|v_k^{+/-}\|}} \quad (21)$$

- ALS
- Мультистарт
  - генерируется с помощью ALS 10-20 пар
  - делается 10-20 итераций целевого метода на каждой паре
  - выбирается пара с наименьшим значением функционала

NMF может применяться к матрицам вероятностей, с единичной суммой столбцов или строк

$$\sum_{i=1}^n h_{ki} = 1 \quad \forall k$$

Показанно, что в локальных минимумах задачи минимизации с дивергенцией Кульбака-Лейблера, суммы по столбцам и строкам матриц  $X$  и  $Q^*$  совпадают, а значит матрица  $Q^*$  тоже будет стохастической, но нет алгоритмов гарантирующих сходимость к локальному минимуму

# Применение к стохастическим матрицам

Так же мы можем потребовать, чтоб  $W$  и  $H$  тоже были стохастическими и учесть это при оптимизации

- Нормировка: после каждого шага нормируем матрицу

$$h_{kj} \leftarrow \frac{h_{kj}}{\sum_{l=1}^r h_{lj}} \quad (22)$$

Может нарушаться монотонность убывания функции потерь.

- Репараметризация: перейдем от матрицы  $H$  к  $Z$

$$h_{kj} \leftarrow \frac{z_{kj}}{\sum_{l=1}^r z_{lj}} \quad (23)$$

1. Постановка задачи
2. Дивергенции
3. Проблемы NMF
4. Мультипликативные обновления
5. Алгоритмы для функций потерь
6. Инициализация алгоритмов
7. Применение к стохастическим матрицам



- Неотрицательные матричные разложения
- Lee, Seung - Algorithms for Non-negative Matrix Factorization